

浙江大学

本科实验报告

课程名称:	课程综合实践 I- 深度学习基础——理论与实践
姓 名:	李昊泽
学 院:	计算机科学与技术学院
系:	
专 业:	计算机科学与技术
学 号:	3250102780
指导教师:	王总辉

2026 年 9 月 12 日

浙江大学实验报告

课程名称: 课程综合实践 I- 深度学习基础——理论与实践 实验类型: 综合

实验项目名称: 基于迁移学习的 CIFAR-10 图像分类

学生姓名: 李昊泽 专业: 计算机科学与技术 学号: 3250102780

实验地点: 紫金港海洋大楼 11 机房 实验日期: 2026 年 9 月 12 日 指导老师: 王总辉

一、实验目标与网络概览

本次课程设计使用课程提供的 CIFAR-10 数据完成十分类，并以飞机 (0)、猫 (3)、青蛙 (6) 三类准确率的平均值作为主要评价指标。我先在本地训练 Wide ResNet 验证数据与推理流程，再采用 ImageNet-1K 预训练的 ConvNeXt-Tiny，在 Kaggle 单张 Tesla T4 上微调。最终模型在 10,000 张验证图像上取得 98.67% 的总体准确率，三类平均准确率为 98.63%。




图 1: 本项目网络结构与训练、推理路径。主干图展示单次前向；TTA 复用同一模型，非两个独立模型。

二、实验原理

1. ConvNeXt 残差块与特征提取

ConvNeXt-Tiny 的块内计算可概括为“ 7×7 逐通道卷积 $\rightarrow$ LayerNorm $\rightarrow$ 通道扩展到 4 倍 $\rightarrow$ GELU $\rightarrow$ 通道投影”，之后经过 Layer Scale 和 stochastic depth，与输入作残差相加。忽略训练中的随机丢弃时，可以简写为 $y = x + \gamma F(x)$ ，其中 γ 是可学习的逐通道缩放系数。

逐通道卷积先在每个通道内提取空间模式，再由通道投影混合不同通道的信息。残差连接提供直接的信息和梯度通路，使网络可以学习对输入特征的修正。LayerNorm 在每个空间位置沿通道归一化，不依赖 batch 内不同样本的统计量；stochastic depth 则在训练时随机跳过部分残差分支，并在推理时恢复全部分支。这些机制分别服务于特征建模、优化稳定性和正则化。

2. 数据增强、标签平滑与 CutMix

随机裁剪、水平翻转和 RandAugment 在标签语义基本不变的前提下改变输入，促使模型不要过度依赖固定位置、朝向或颜色。增强强度也不能无限增加：CIFAR-10 原图只有 32×32 ，过强的几何和颜色变化可能破坏本来就有限的类别线索。

对于十分类 one-hot 标签 y ，标签平滑将目标改为 $q_k = (1 - \varepsilon)y_k + \frac{\varepsilon}{10}$ 。本实验取 $\varepsilon = 0.05$ ，正确类目标为 0.955，其余每类为 0.005；损失为软标签交叉熵 $L = -\sum_{k=1}^{10} q_k \ln p_k$ 。它减弱了模型将训练样本置信度推向极端的倾向，但不意味着预测概率已经得到良好校准。

CutMix 用另一张图像的矩形区域替换当前图像的一部分。设二值掩码 M 在保留原图的位置为 1，则：

$$\tilde{x} = M \cdot x_a + (1 - M) \cdot x_b, \quad \tilde{q} = \lambda q_a + (1 - \lambda) q_b.$$

其中乘法按像素逐元素进行， λ 是原图实际保留的面积比例。矩形被图像边缘裁切后要重新计算该比例，不能直接使用最初采样值。模型因此需要从部分可见区域判断类别；训练目标变得更软、更难，也解释了启用 CutMix 后 loss 与验证准确率未必同步变化。

3. AdamW、warmup 与余弦退火

Adam 根据梯度的一阶、二阶矩估计调整各参数的更新尺度。**AdamW** 在此基础上把权重衰减与自适应梯度更新分开，其更新可概括为：

$$\theta_{t+1} = (1 - \eta_t \lambda_w) \theta_t - \eta_t \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon}.$$

这里 $\hat{m}_t$ 、 $\hat{v}_t$ 是偏差修正后的矩估计， λ_w 为衰减系数。与把 L2 项直接加入 Adam 的梯度不同，解耦的衰减不会再经过二阶矩的逐参数缩放。本实验对卷积、线性层权重使用 0.05 的衰减，对 bias 和一维归一化参数不衰减。

warmup 在微调初期逐步增大学习率，缓和解冻骨干后的更新；余弦退火则在后期逐渐缩小步长。对本实现，warmup 后的倍率为 $r(p) = 0.02 + 0.98 \frac{1 + \cos(\pi p)}{2}$ ， p 表示该段调度的归一化进度，实际学习率为基础学习率乘以 $r(p)$ 。当前保留 30 轮调度但只执行了 9 轮微调，因此没有到达余弦曲线的末端。

4. EMA 与测试时增强：平滑对象不同

EMA 平滑的是训练过程中的模型参数。若第 t 次更新的参数为 θ_t ，则维护：

$$\bar{\theta}_t = d_t \bar{\theta}_{t-1} + (1 - d_t) \theta_t.$$

本实验采用 $d_t = \min(0.999, \frac{1+t}{10+t})$ ，初期较小的衰减让 EMA 较快跟随刚开始适应任务的分类头，后期再提高平滑程度。这样可以减弱单次 mini-batch 更新的波动，但 EMA 并不保证一定优于原始权重，仍需要验证结果判断。

TTA 平滑的是同一输入不同视图下的预测。评估时对原图和水平翻转图各进行一次前向，将 logits 平均：

$$z(x) = \frac{f_{\bar{\theta}}(x) + f_{\bar{\theta}}(T(x))}{2}.$$

其中 T 为水平翻转。它在两个视图都保持类别语义时可能减少方向敏感性，代价是两次前向计算。实现中平均的是 logits，不是先做 softmax 后平均概率；这两种操作通常不等价。EMA 与 TTA 可以同时使用，但分别属于参数层面和预测层面的平滑。

5. AMP、梯度累积与梯度裁剪

自动混合精度 (AMP) 为适合的运算选择低精度，并保留必要的高精度计算；GradScaler 通过先放大 loss、反向传播后再还原梯度，降低 FP16 小梯度下溢的风险。检测到溢出时可跳过本次优化器更新，EMA 也应跳过同步。

梯度累积将两个 batch 的梯度按样本数加权后再更新一次，32 的实际 batch 因而对应 64 的等效 batch；这减少单次前向需要保留的激活，但不是免费提速。梯度裁剪则限制梯度整体范数，抑制异常大的更新。实现中先撤销梯度缩放，再按最大范数 1.0 裁剪，避免把放大后的梯度误当作真实梯度处理。

三、模型实现

1. 数据划分与评价指标

用途	课程文件	总数	每类数量
训练	data_batch_1 至 data_batch_5	50,000	5,000
验证、选择模型	test_batch	10,000	1,000

数据读取后检查形状为 $(N, 32, 32, 3)$ 、标签范围为 0 至 9，并逐类统计数量。只有训练集参与梯度更新；验证集只用于评估与选择权重。微调阶段没有另外加入外部图像，但模型初始化使用了外部 ImageNet-1K 预训练知识。

模型仍输出全部十类。设第 c 类的正确数为 n_c 、样本数为 N_c ，则 $A_c = \frac{n_c}{N_c}$ ，评分指标 $S = \frac{A_0 + A_3 + A_6}{3}$ 。每轮记录总体准确率、十类准确率和混淆矩阵；选模时优先比较 S ，仅在 S 相同时比较总体准确率。

2. 从本地基线到迁移学习

最初采用 WRN-16-2 从零训练，模型较小，便于在本地 CPU 上检查十分类训练、模型保存及重载流程。归档 Notebook 的 20 轮训练记录对应的最佳模型总体准确率为 87.15%，其中猫类只有 71.70%，限制了评分三类的平均值。随后我将重点转向预训练特征的适配，希望在有限训练时间内得到更好的分类能力。

已完成方案	总体	飞机	猫	青蛙
WRN-16-2，本地从零训练	87.15%	87.80%	71.70%	93.50%
ConvNeXt-Tiny，Kaggle 微调	98.67%	99.60%	96.70%	99.60%

两者的三类平均准确率分别为 84.33% 和 98.63%。不过，这并不是只改变“是否预训练”的对照实验：架构、分辨率、优化器和训练设备也同时变化。

3. ConvNeXt-Tiny 的十分类改造

本实验直接使用 TorchVision 的官方实现及 `IMAGENET1K_V1` 权重，将末层从 1,000 类改为 10 类，重新初始化分类层。修改后的参数量为 27,827,818。四个特征阶段的通道数与块数见图 1，训练时最大 stochastic depth 概率设为 0.1。训练新分类头时冻结特征提取部分，再解冻全部网络。

4. 输入处理与分辨率

训练增强先在原始图像上完成：反射填充 4 像素的随机裁剪、水平翻转，以及 RandAugment (2 个操作，强度 7)。模型内部再双线性插值到 224×224 ，并使用 ImageNet 的均值 (0.485, 0.456, 0.406) 和标准差 (0.229, 0.224, 0.225) 归一化。这里没有照搬 ImageNet 默认的 236 缩放加中心裁剪，而是保留整幅 CIFAR-10 图像。

放大不会凭空恢复低分辨率中丢失的纹理。我采用 224 输入，主要是为了让预训练网络在更接近原有空间尺度的条件下工作，代价是计算量增加。是否能缩小到 160 或 192 并保持成绩，需要额外对照实验，本次没有作出结论。

四、训练实现

1. 两阶段微调与主要参数

第一阶段只训练新分类头及分类部分的归一化参数，让随机初始化的输出层先适应十分类。第二阶段解冻全网络，骨干学习率设置为分类头的十分之一，减少对已有特征的剧烈更新。两阶段均使用 AdamW。

项目	本次正式运行配置
分类头阶段	2 epochs；学习率 0.001；骨干冻结
全网络阶段	最多 10 epochs，实际 9；骨干 0.00005，分类头 0.0005
学习率调度	微调前 3 轮 warmup；沿用 30 轮配方的余弦调度
Batch 与累积	训练 batch 32，梯度累积 2，等效 batch 64；验证 batch 32
Weight decay	0.05；bias 和一维归一化参数不衰减
损失与标签	软标签交叉熵；label smoothing = 0.05
CutMix	微调时以 0.25 概率执行；Beta(1,1) 采样混合比例
数值与显存	CUDA AMP、channels_last、梯度范数裁剪 1.0
EMA	最大衰减 0.999；初期渐增衰减
验证	EMA 权重，原图与水平翻转两视图 TTA

实现时先平滑标签，再按实际替换面积执行 CutMix 标签混合。分类头阶段关闭 CutMix，全网络微调阶段按 25% 概率启用；验证时不进行训练增强。

EMA 对训练权重作指数平滑，每次有效的优化器更新后才同步；AMP 因溢出跳过更新时，EMA 也不更新。评估时用同一个模型分别预测原图和水平翻转图，再平均 logits。最终保存的是一份 EMA 模型权重，没有使用多个独立模型的集成。

2. 配方轮数与实际执行轮数

配置中保留的 30 轮是学习率调度的参考长度，不是本次实际跑了 30 轮。执行上限由 10 轮微调限制，预算不足又使第 10 轮未开始。相应地，本次并没有走完余弦退火，也没有进入原配方“最后 5 轮关闭 CutMix”的阶段；实际 9 轮微调均允许以 25% 概率执行 CutMix。

五、训练过程与总体结果




图 2: Notebook 原始学习曲线。横轴为累计 epoch，前 2 轮训练分类头，第 3 轮开始全网络微调；准确率来自 EMA + 双视图 TTA。

阶段 / 轮次	训练 loss	总体准确率	目标三类均值
分类头 1	0.6830	93.66%	92.73%
分类头 2	0.5922	93.95%	92.97%
微调 1	0.6793	96.93%	95.87%
微调 2	0.5942	97.72%	97.37%
微调 3	0.5539	98.10%	97.73%
微调 4	0.5193	98.28%	97.90%
微调 5	0.5154	98.49%	98.13%
微调 6	0.4883	98.51%	98.20%
微调 7	0.5013	98.55%	98.20%
微调 8	0.4921	98.50%	98.30%
微调 9	0.4726	98.67%	98.63%

冻结骨干训练 2 轮后，三类均值为 92.97%；解冻后的第一轮即提高到 95.87%，说明当前预训练特征经过任务适配后还有明显提升空间。进入微调时 loss 从 0.5922 上升到 0.6793，但验证准确率反而提高。

模型选择规则也在日志中得到了具体体现：微调第 7 到第 8 轮，总体准确率从 98.55% 降到 98.50%，三类均值却从 98.20% 升到 98.30%，因此仍更新最佳权重。第 9 轮再次同时改善两个指标，成为最终选择的第 11 个累计 epoch。

六、结果与误差分析

最终使用最佳 EMA 权重重新评估全部 10,000 张验证图像。正确分类 9,867 张；评分三类共正确分类 2,959 / 3,000 张，均值为 $\frac{99.60\%+96.70\%+99.60\%}{3} = 98.63\%$ （四舍五入）。下表中加粗的类别是课程评分类别，各类均有 1,000 张图像。

类别	正确数	准确率	类别	正确数	准确率
飞机	996	99.60%	狗	971	97.10%
汽车	990	99.00%	青蛙	996	99.60%
鸟	989	98.90%	马	994	99.40%
猫	967	96.70%	船	994	99.40%
鹿	985	98.50%	卡车	985	98.50%




图 3: Notebook 原始混淆矩阵。行为真实类别，列为预测类别；对角线是正确分类数量。目标三类共错分 41 张，其中猫类占 33 张，约为 80.5%。飞机和青蛙已经各只错 4 张，后续若要提高三类平均分，猫类是更值得排查的瓶颈。但这不意味着可以忽略狗等非评分类别：猫被误判为狗 23 次，狗被误判为猫也为 23 次，两种方向合计占全部 133 次错误的约 34.6%。学好相近类别之间的边界，对目标类别同样重要。

低分辨率、姿态与背景可能使猫狗的区分更加困难，不过混淆矩阵只能证明错误集中在哪里，不能单独证明原因。下一步应查看这 46 张错分图像，再判断问题主要来自主体细节、遮挡还是背景干扰，而不是看到数字后直接认定模型“只学到了背景”。

七、运行检查

最佳模型验证与权重重载

来源：3250102780_李昊泽.ipynb · Kaggle 已保存输出 · 此页为导出内容截图，非重新运行

第 21 节：完整验证集结果（原始输出）

```
最佳轮次: {'stage': 'finetune', 'epoch': 9, 'global_epoch': 11, 'source': 'ema'}
验证样本数: 10000
总体 98.67% | 飞机/猫/青蛙均值 98.63%
airplane: 99.60% | automobile: 99.00% | bird: 98.90% | cat: 96.70% | deer: 98.50% | dog: 97.10% | frog:
99.60% | horse: 99.40% | ship: 99.40% | truck: 98.50%
```

第 24 节：重建 net 并检查一致性（代码节选）

```
net = CIFAR10TransferNet(**MODEL_CONFIG, pretrained=False)
net.to(device, memory_format=torch.channels_last)
net.load_state_dict(torch.load(FINAL_MODEL_PATH, map_location=device, weights_only=True))
net.eval()
with torch.inference_mode(), amp.autocast():
    reloaded_logits = net(verification_images).float().cpu()
torch.testing.assert_close(expected_logits, reloaded_logits, rtol=1e-4, atol=1e-5)
assert torch.equal(expected_logits.argmax(1), reloaded_logits.argmax(1))
assert reloaded_logits.shape == (len(verification_images), 10) and torch.isfinite(reloaded_logits).all()
assert not net.training
```

第 24 节运行结果（原始输出）

```
最终验证通过: net 已保存并重新加载, net.eval() 已生效, 真实 batch 预测一致。
最终模型: /kaggle/working/convnext_tiny_1h_v1_kaggle/cifar10_convnext_tiny.pth
本次从模型准备完成到最终保存共 66.5 分钟。
```

图 4: Notebook 第 21、24 节已保存的代码与输出节选，由导出内容渲染截图。重载检查使用 2 张真实验证图像，不代表新一次训练。

最终用 `torch.save` 保存 `net.state_dict()`，导出文件名为 `cifar10_convnext_tiny.pth`。重建时关闭预训练下载，用 `map_location` 加载完整状态，再进入评估模式。图中检查了保存前后 logits 在给定浮点容差内接近、预测标签一致、输出形状正确、数值有限，以及 `net.training` 为假。

八、讨论与改进

以下改进围绕当前模型的误差和计算成本展开，尚未实际执行；比较时应保留同一基线，避免同时改变多个因素后无法解释结果。

1. 优先排查猫狗边界，而不是只增加目标类别权重

目标三类的 41 次错误中有 33 次来自猫，且猫狗互判共 46 次。后续应先整理这些错分图像的预测置信度，并按主体过小、遮挡、背景复杂等现象分组，再检查训练集中是否缺少相应模式。若错误集中于主体位置，可对比更温和的裁剪或遮挡增强；如果主体细节已经被原图分辨率限制，单纯提高插值尺寸未必有效。

这类改动仍应训练完整十类，记录猫类召回、狗类召回及两个方向的混淆数量。仅提高猫类权重可能把更多狗误判成猫，因此不能只看猫类一个指标。公开验证集的错分图像用于诊断，不应直接并入训练集。

2. 让学习率与增强策略匹配短训练周期

当前微调只完成 9 轮，却沿用 30 轮的学习率和 CutMix 关闭时间。可先只将调度长度改为计划执行的 10 轮，保留 3 轮 warmup，比较同一时间预算下的最优三类均值；再单独测试最后 2 轮关闭 CutMix，让模型在收尾阶段适应未混合样本。两项修改应分开实验，不能把可能的改善预先写成既定收益。

固定轮数不一定对应固定成本，因此比较时还应记录达到 95%、98% 三类均值所需的时间，以及最佳权重出现的轮次。若短调度反而更早停滞，可考虑延长高学习率阶段，而不是默认越快降低学习率越好。

3. 通过消融确定分辨率、EMA 与 TTA 是否值得保留

先对同一份最佳权重比较单视图与双视图 TTA，记录三类均值、十类总体准确率和推理耗时；这项检查不需要重新训练。之后分别在 160、192、224 输入尺寸下按相同预算训练，避免只在 224 训练的权重上临时改尺寸，就宣称得到了低分辨率训练结论。EMA 的作用则应在同一训练轨迹中比较原始权重和 EMA 权重。

若某项方法带来的精度变化小于重复实验的波动，却明显增加耗时，就应优先选择更简单的配置。标签平滑和 CutMix 强度也可逐项消融，但不宜在一次实验中同时修改模型、分辨率和增强策略。

参考资料

1. 课程资料
2. 本报告的部分文字组织、代码核对与排错分析由 OpenAI Codex 辅助完成。所有实验数据、运行输出和技术描述均由本人检查，最终报告由本人审阅并负责。