

# 浙江大学

## 本科实验报告

|       |                            |
|-------|----------------------------|
| 课程名称: | 课程综合实践 I-<br>深度学习基础——理论与实践 |
| 姓 名:  | 李昊泽                        |
| 学 院:  | 计算机科学与技术学院                 |
| 系:    |                            |
| 专 业:  | 计算机科学与技术                   |
| 学 号:  | 3250102780                 |
| 指导教师: | 王总辉                        |

2026 年 9 月 4 日

# 浙江大学实验报告

课程名称: 课程综合实践 I- 深度学习基础——理论与实践 实验类型: 综合

实验项目名称: 实验五: 迁移学习

学生姓名: 李昊泽 专业: 计算机科学与技术 学号: 3250102780

实验地点: 紫金港海洋大楼 11 机房 实验日期: 2026 年 9 月 4 日 指导老师: 王总辉

## 摘要

车辆分类部分构建普通 CNN 作为对照, 并采用 ImageNet 预训练 VGG16-BN, 先训练新分类头, 再解冻最后一个卷积块进行小学习率微调。1646 条数据按 D5 的原顺序划分为 1481 条训练样本和 165 条验证样本。CNN 最佳验证准确率为 **86.06%**, VGG16-BN 最终保留模型为 **94.55%**, 提高约 8.48 个百分点。

智能狗门部分先直接使用预训练 VGG16 区分狗、猫和其他对象, 再添加单输出线性层, 训练只允许柯基犬 Penny 进入的个性化狗门。Penny 模型冻结阶段最高验证准确率为 **90.91%**, 冻结阶段末轮及微调结束时均为 **81.82%**。

## 实验目的

1. 理解迁移学习如何复用预训练模型的特征, 并掌握冻结参数、替换或添加分类层、小学习率微调的方法。
2. 在相同数据划分下比较自定义 CNN 和迁移学习模型的验证准确率。
3. 理解类别标签、logits、损失函数和判定阈值的关系, 并完成车辆分类提交及个性化狗门判断。

# 实验原理

## 一、预训练特征与迁移学习

迁移学习把在较大数据集上训练得到的参数作为新任务的起点,使小数据集不必从随机参数开始学习全部特征。

将模型写为  $z = g_{\varphi}(f_{\theta}(x))$ , 其中  $f_{\theta}$  表示复用的网络部分,  $g_{\varphi}$  表示新分类层。冻结阶段固定  $\theta$ , 只更新  $\varphi$ ; 微调阶段允许部分或全部  $\theta$  参与更新, 并使用较小学习率:

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L$$

先训练分类头, 是为了让随机初始化的新层先适应已有表示; 随后再调整预训练参数, 减少训练初期较大更新对原有特征的破坏。微调是否有效仍需由验证结果判断。

## 二、两种分类头的区别

| 任务       | 实际网络改动                                            | 输出与损失             |
|----------|---------------------------------------------------|-------------------|
| 车辆分类     | 替换 VGG16-BN 最后的线性层:<br>4096 $\rightarrow$ 类别数 $C$ | $C$ 个 logits; 交叉熵 |
| Penny 狗门 | 保留完整 VGG16, 在 1000 维输出<br>后添加 Linear(1000, 1)     | 1 个 logit; 二元交叉熵  |

车辆分类模型直接接收未归一化的类别分数, 由 `CrossEntropyLoss` 计算损失。若真实类别为  $y$ , 则单样本损失为:

$$L = -\log\left(\frac{\exp(z_y)}{\sum_{k=0}^{C-1} \exp(z_k)}\right)$$

Penny 模型使用 `BCEWithLogitsLoss`, 内部结合 Sigmoid 和二元交叉熵。设  $p = \sigma(z) = \frac{1}{1 + \exp(-z)}$ , 则:

$$L = -y \log(p) - (1 - y) \log(1 - p)$$

## 三、冻结参数

`requires_grad_(False)` 控制参数是否计算梯度; `train()` 和 `eval()` 控制 Dropout、BatchNorm 等层的行为; `torch.no_grad()` 关闭梯度记录。三者作用不同。即使基础网络参数已被冻结, 调用整个模型的 `train()` 仍会开启其中的 Dropout。

# 实验一：Kaggle 车辆图像分类

## 一、数据处理

训练图像转换为 RGB，随机裁剪为  $224 \times 224$ ，进行水平翻转与轻量颜色扰动，再转为张量并使用 ImageNet 均值、标准差归一化。验证与提交图像采用短边缩放到 256、中心裁剪到  $224 \times 224$  和相同归一化。输入张量形状为  $B \times 3 \times 224 \times 224$ 。

## 二、普通 CNN 对照模型

对照模型使用两组卷积、批归一化、ReLU 和最大池化提取特征，再通过自适应平均池化和全连接层完成分类。其主要尺寸变化如下：

| 网络层                                                             | 输出尺寸                       |
|-----------------------------------------------------------------|----------------------------|
| 输入                                                              | $3 \times 224 \times 224$  |
| $3 \times 3$ 卷积, $3 \rightarrow 16$ ; BN、ReLU、 $2 \times 2$ 池化  | $16 \times 112 \times 112$ |
| $3 \times 3$ 卷积, $16 \rightarrow 32$ ; BN、ReLU、 $2 \times 2$ 池化 | $32 \times 56 \times 56$   |
| 自适应平均池化                                                         | $32 \times 7 \times 7$     |
| Flatten、Dropout(0.35)、Linear、ReLU                               | $1568 \rightarrow 128$     |
| Dropout(0.20)、Linear                                            | $128 \rightarrow C$        |

当前二分类模型共有 206,226 个可训练参数，输出形状为批大小 $\times$ 2。模型采用 Adam，学习率为  $10^{-3}$ ，交叉熵损失，训练 15 轮。实际运行的 batch size 为 32。

## 三、VGG16-BN 冻结训练与微调

加载 ImageNet 预训练 VGG16-BN 后，首先冻结原有参数，再将最后一层替换为适合本任务的线性层。由于新层是在冻结之后创建，其参数仍可训练。

```
1 for parameter in transfer_model.parameters():
2     parameter.requires_grad = False
3
4 in_features = transfer_model.classifier[-1].in_features
5 transfer_model.classifier[-1] = nn.Linear(in_features, NUM_CLASSES)
```

冻结阶段训练新分类头 10 轮。随后解冻第 5 个卷积块 `features[34:]`，微调 5 轮，并为卷积块与分类头设置不同学习率。

| 阶段          | 可训练部分         | 优化设置                         | 轮数 |
|-------------|---------------|------------------------------|----|
| 普通 CNN      | 整个网络          | Adam；学习率 $1e-3$              | 15 |
| VGG16-BN 冻结 | 最后的分类层        | AdamW；学习率 $1e-3$             | 10 |
| VGG16-BN 微调 | 第 5 卷积块与最后分类层 | AdamW；卷积块 $1e-5$ ，分类层 $1e-4$ | 5  |

两个 AdamW 阶段均设置权重衰减  $10^{-4}$ 。

四、实验结果与分析

| 评价项目                     | 实际结果   |
|--------------------------|--------|
| 普通 CNN 最佳验证准确率（第 11 轮）   | 86.06% |
| VGG16-BN 冻结阶段最佳（第 10 轮）  | 94.55% |
| VGG16-BN 微调阶段自身最高（第 5 轮） | 92.73% |
| VGG16-BN 最终保留模型的验证准确率    | 94.55% |
| 迁移学习相对 CNN 的提升（百分点）      | 约 8.48 |
| Kaggle Accuracy Score    | 0.9333 |




Figure 1: 训练曲线对比图




Figure 2: 混淆矩阵

非应急车辆有 108 张，precision 为 0.9541、recall 为 0.9630；应急车辆有 57 张，precision 为 0.9286、recall 为 0.9123。整体准确率为 0.9455，macro F1 为 0.9394。应急车辆的召回率相对较低，说明除了总体正确率，还应关注漏识别应急车辆的问题。

## 实验二：预训练模型与个性化狗门

### 一、普通狗门：直接使用 VGG16

05a 直接加载预训练 VGG16, 不执行新任务训练。使用权重自带的图像变换后, 单张图片变为  $1 \times 3 \times 224 \times 224$ , 网络输出  $1 \times 1000$  的类别分数。使用 `argmax(dim=1)` 沿类别维选择预测索引, 再查阅 `imagenet_class_index.json`。

狗门按索引范围执行规则: 151 – 268 判为狗并放行; 281 – 285 判为猫并留在屋内; 其他类别拒绝进入。保存输出如下:

### 二、网络构建

05b 使用 Penny the Corgi 数据集, 按 `Penny` 和 `Not_Penny` 子目录生成标签, 编码依次为 0 和 1。Dataset 读取图像并执行 VGG16 权重自带预处理; 之后用 `random_split` 按 80%/20% 划分训练集与验证集, batch size 为 32。

个性化狗门的结构为完整 VGG16 后接一个线性层:

```
1 vgg_model.requires_grad_(False)
2 my_model = nn.Sequential(
3     vgg_model,
4     nn.Linear(1000, 1)
5 )
6 loss_function = nn.BCEWithLogitsLoss()
7 optimizer = Adam(my_model.parameters())
```

 Python

新增层有  $1000 \times 1 + 1 = 1001$  个参数。冻结检查的输出中, 原 VGG16 参数均为 False, 新层的权重和偏置为 True。实验先冻结训练 10 轮, 采用 Adam 默认学习率  $10^{-3}$ ; 再解冻全部 VGG16 参数, 重新创建学习率为  $10^{-6}$  的 Adam, 微调 2 轮。训练增强包括  $\pm 25^\circ$  旋转、面积比例 0.8 – 1.0 的随机裁剪、水平翻转及颜色扰动。当前实现先执行标准化, 再在训练循环对张量增强; 这一顺序在颜色处理上存在局限, 见后文讨论。

### 三、冻结阶段的训练结果

准确率由每批预测正确数量累加后除以整个数据集大小得到。以下指标按 notebook 保存的日志记录; 为便于阅读, 表中轮次从 1 开始, 原输出中的 epoch 则从 0 开始。

| 轮次 | 训练准确率  | 验证准确率  | 训练 Loss | 验证 Loss |
|----|--------|--------|---------|---------|
| 1  | 68.94% | 84.85% | 3.2595  | 0.8876  |
| 2  | 78.79% | 84.85% | 2.2707  | 0.7319  |
| 3  | 76.52% | 84.85% | 2.2451  | 0.7053  |
| 4  | 74.24% | 87.88% | 2.0107  | 0.7721  |
| 5  | 87.12% | 87.88% | 1.4656  | 0.9854  |
| 6  | 81.06% | 90.91% | 1.7347  | 0.9469  |
| 7  | 81.82% | 84.85% | 1.8280  | 0.7475  |
| 8  | 84.09% | 84.85% | 2.5188  | 0.7526  |
| 9  | 83.33% | 81.82% | 1.6298  | 0.7695  |
| 10 | 89.39% | 81.82% | 1.0817  | 0.8001  |

冻结阶段的最佳验证准确率出现在第 6 轮，为 90.91%；末轮为 81.82%，下降 9.09 个百分点。

#### 四、微调

| 微 调 轮 次 | 训练准确率  | 验证准确率  | 训练 Loss | 验证 Loss |
|---------|--------|--------|---------|---------|
| 1       | 92.42% | 81.82% | 1.1115  | 0.7989  |
| 2       | 85.61% | 81.82% | 1.7697  | 0.7944  |

微调前末轮验证准确率为 81.82%，微调两轮后仍为 81.82%，提升为 0.00 个百分点。验证 Loss 从 0.8001 略降至 0.7944，但分类正确率没有改善。相对冻结阶段历史最佳 90.91%，最终结果仍低 9.09 个百分点。

#### 五、个性化狗门预测

模型输出一个 logit，使用 `pred < 0` 判为 Penny。

| 图片（类别 / 文件名）        | logit 或输出 | 判定分析         |
|---------------------|-----------|--------------|
| Penny / 006.JPG     | -3.7228   | 判为 Penny，正确  |
| Not_Penny / 021.jpg | -0.2752   | 判为 Penny，误放行 |
| Not_Penny / 042.jpg | 这不是 Penny | 拒绝进入，正确      |
| Penny / 030.jpg     | 是 Penny   | 允许进入，正确      |

其中非 Penny 图片 021.jpg 的输出为负，说明模型可能错误放行其他动物，不能只展示成功案例就断言狗门已经可靠。该值接近阈值 0，也反映出这次预测的分类边界较不明确。

为测试模型是否放行其他动物，并减少给出图片对预测的干扰，可以使用网络的随机图片进行预测。





Figure 3: 预测结果成功

## 实验问题与改进思考

### 一、推理稳定性

Penny 数据处理中，ColorJitter 的色相变换不宜作用于可能含负值的标准化张量。更合理的流程是先在原图或合法像素范围内执行几何和颜色增强，再转为张量并进行 ImageNet 标准化。此处指出的是当前实现的改进方向，不将修正后的效果写作已完成的实验结果。

### 二、迁移学习效果

迁移学习的价值在于复用已有的视觉表示，使小数据任务能够从较好的参数起点开始学习。冻结、微调、数据增强和模型选择需要配合使用；微调并非必然提高准确率。本次 Penny 日志尤其说明，应根据验证结果选择权重，而不能只按训练轮数或训练准确率判断模型优劣。

## 参考资料

1. 课程资料
2. 本报告的部分文字组织、代码核对与排错分析由 OpenAI Codex 辅助完成。所有实验数据、运行输出和技术描述均由本人检查，最终报告由本人审阅并负责。