

浙江大学

本科实验报告

课程名称:	课程综合实践 I- 深度学习基础——理论与实践
姓 名:	李昊泽
学 院:	计算机科学与技术学院
系:	
专 业:	计算机科学与技术
学 号:	3250102780
指导教师:	王总辉

2026 年 9 月 8 日

浙江大学实验报告

课程名称: 课程综合实践 I- 深度学习基础——理论与实践 实验类型: 综合

实验项目名称: 实验七: 生成对抗网络 GAN

学生姓名: 李昊泽 专业: 计算机科学与技术 学号: 3250102780

实验地点: 紫金港海洋大楼 11 机房 实验日期: 2026 年 9 月 8 日 指导老师: 王总辉

摘要

本实验实现了无条件生成对抗网络和条件生成对抗网络。实验一使用 71,314 张动漫人脸训练 DCGAN, 将 100 维随机噪声逐步上采样为 64×64 RGB 图像; 完整训练 1 个 epoch 后, 判别器和生成器平均 BCE 损失分别为 0.2529 和 6.1487, 并成功生成、保存 100 张动漫人脸。

实验二在 60,000 张 MNIST 训练图像上训练条件 GAN, 把数字类别作为附加条件输入生成器和判别器; 完整训练 10 个 epoch 后, 判别器损失为 0.5365, 生成器损失为 1.1833, 模型能够按标签生成 0-9, 并能单独生成数字 7。

实验原理

一、生成对抗网络

GAN 由生成器 G 和判别器 D 组成。生成器接收随机噪声 z , 输出生成样本 $G(z)$; 判别器接收真实样本或生成样本, 输出其为真实数据的概率。经典 GAN 的目标可写为:

$$\min_G \max_D V(D, G) = E_x[\ln D(x)] + E_z[\ln(1 - D(G(z)))]$$

判别器希望增大真实样本的输出并减小生成样本的输出; 生成器则希望使 $D(G(z))$ 接近 1。两个网络交替更新, 因此训练不是普通的单目标最小化, 而是动态博弈过程。

二、DCGAN 与转置卷积

实验一采用 DCGAN。生成器先用全连接层把低维噪声映射为小尺寸多通道特征图,再用转置卷积逐步扩大空间尺寸。若普通卷积用于下采样和提取判别特征,转置卷积则通过可学习权重完成上采样。生成器中使用 BatchNorm 和 ReLU 稳定训练,最后使用 Tanh,使输出范围与归一化后的真实图像 $[-1, 1]$ 一致。

判别器使用步长为 2 的卷积逐步缩小图像,配合 LeakyReLU 保留负半轴梯度,最后通过 Sigmoid 得到真假概率。实验中的权重以均值 0、标准差 0.02 的正态分布初始化。

三、条件 GAN

普通 GAN 只学习 $G(z)$,无法直接控制输出类别。条件 GAN 引入标签 y ,把两个网络写为 $G(z, y)$ 和 $D(x, y)$ 。实验二把数字标签通过嵌入层转换为连续向量:生成器将 100 维噪声与 10 维标签表示拼接,判别器将展平后的图像与 784 维标签表示拼接。

条件信息同时约束生成和判别:生成器不仅要生成“像手写数字”的图像,还要与指定标签一致;判别器则判断“图像和标签这一组合”是否来自真实数据。因此,在噪声不同而标签相同的情况下,模型应生成书写风格不同但类别一致的数字。

四、GAN 损失与生成质量

GAN 的损失不能按普通分类任务的方式单调解释。判别器过强时, L_D 可能很低而 L_G 很高;生成器改善后,判别器面对更逼真的假样本, L_D 反而可能上升。因此本实验同时保存固定噪声的阶段生成结果,通过相同输入在不同 epoch 的变化判断模型是否学到轮廓、类别与细节。

实验一：DCGAN 动漫人脸生成

一、数据预处理

- 1. 将图像统一转换为 RGB。
- 2. 缩放到 64×64 。
- 3. 转换为通道优先的张量 $3 \times 64 \times 64$ 。
- 4. 按三个通道的均值 0.5、标准差 0.5 归一化，使像素范围由 $[0, 1]$ 映射到 $[-1, 1]$ 。

二、网络结构

生成器输入为 100 维标准正态噪声，先映射为 $512 \times 4 \times 4$ 特征图，再通过四层转置卷积生成 RGB 图像：

生成阶段	输出尺寸	激活与归一化
Linear、reshape	$512 \times 4 \times 4$	BatchNorm、ReLU
转置卷积 $512 \rightarrow 256$	$256 \times 8 \times 8$	BatchNorm、ReLU
转置卷积 $256 \rightarrow 128$	$128 \times 16 \times 16$	BatchNorm、ReLU
转置卷积 $128 \rightarrow 64$	$64 \times 32 \times 32$	BatchNorm、ReLU
转置卷积 $64 \rightarrow 3$	$3 \times 64 \times 64$	Tanh

三、训练设置

参数	取值	参数	取值
随机种子	2021	噪声维数	100
batch size	64	训练轮数	1
每轮批次数	1114	学习率	10^{-4}
损失函数	BCELoss	优化器	Adam
Adam betas	(0.5, 0.999)	计算设备	CPU

每个批次先更新判别器：分别计算真实图像与生成图像的 BCE，并取二者平均；随后更新生成器，使同一批生成图像被判别器判断为真实。生成图像在判别器更新时使用 `detach`，避免判别器反向传播同时修改生成器。

四、实验结果与分析

完整 1 个 epoch 的实际结果如下：

评价项目	实际结果
判别器平均 BCE	0.2529
生成器平均 BCE	6.1487




Figure 1: 生成结果

生成结果已出现动漫人脸的整体结构，能够观察到头发、眼睛、肤色和脸部轮廓，并且颜色与发型存在一定差异，说明模型在一个 epoch 内已学习到主要视觉分布。但图像仍有较明显的颗粒噪声，部分眼睛、嘴部和轮廓模糊；不同样本的构图也较相似。

实验二：条件 GAN 手写数字生成

一、条件生成器

数字标签首先经过 `Embedding(10, 10)` 得到 10 维向量，再与 100 维噪声拼接为 110 维输入。网络结构为：

$$110 \rightarrow 256 \rightarrow 512 \rightarrow 1024 \rightarrow 784$$

前三个全连接层后使用 ReLU，最后使用 Tanh，并将 784 维输出还原为 $1 \times 28 \times 28$ 。生成器共有 1,489,012 个可训练参数。

二、条件判别器

真实或生成图像展平为 784 维，标签通过 `Embedding(10, 784)` 得到同尺寸条件表示，二者拼接为 1568 维。网络结构为：

$$1568 \rightarrow 1024 \rightarrow 512 \rightarrow 256 \rightarrow 1$$

隐藏层使用斜率 0.2 的 LeakyReLU，最后使用 Sigmoid。判别器共有 2,270,881 个可训练参数。形状测试显示，4 张生成图像的输出为 `(4, 1, 28, 28)`，对应判别结果为 `(4, 1)`。

三、训练设置

参数	取值	参数	取值
随机种子	42	噪声维数	100
类别数	10	batch size	64
训练轮数	10	每轮批次数	938
学习率	2×10^{-4}	损失函数	BCELoss
优化器	Adam	Adam betas	<code>(0.5, 0.999)</code>




Figure 2: 训练曲线

四、损失变化

轮次	L_D	L_G	轮次	L_D	L_G
1	0.3423	1.9957	6	0.4464	1.5198
2	0.3021	2.1338	7	0.4777	1.3927
3	0.3375	1.9634	8	0.5033	1.2950
4	0.3964	1.6923	9	0.5202	1.2392
5	0.4154	1.6230	10	0.5365	1.1833

第 2 轮生成器损失短暂升至 2.1338，之后总体下降到 1.1833；判别器损失从早期约 0.30 逐步上升到 0.5365。这说明生成器逐渐提高了欺骗判别器的能力，使两者的对抗关系更接近平衡。

五、生成结果

第 1 个 epoch 时，数字轮廓中仍有较多噪点，部分数字难以辨认；到第 5 个 epoch，0-9 的主要结构已形成；第 10 个 epoch 时，同一行的 5 张图片基本都符合该行标签，同时笔画粗细和倾斜程度存在差异。该变化表明条件信息控制有效，随机噪声则保留了同类样本内部的多样性。

Labels 0-9, five samples per row



将条件标签固定为 7 后，模型生成的 16 张图像均具有数字 7 的主要笔画结构，说明模型能够按指定类别生成，而不是只能随机产生任意数字。样本之间在线条弯曲、倾斜和粗细上存在差异；少量样本仍有断裂或局部模糊，说明训练轮数和全连接结构仍限制了细节质量。

讨论与改进

1. 动漫人脸只训练 1 个 epoch，虽然已生成可辨识轮廓，但细节仍较粗糙；需要增加训练轮数并保存更多中间样例。
2. 两个实验主要采用人工观察生成质量，尚未计算 FID、KID 等分布级指标，也没有独立评估样本多样性。
3. MNIST 条件 GAN 使用全连接网络，忽略了图像的二维局部结构；可改为条件卷积 GAN，提高笔画连续性。
4. 当前运行使用 CPU，完整训练耗时较长；若迁移到 GPU，应重新核对设备、随机性与实际运行日志，不能直接把 CPU 结果视为 GPU 复现结果。

参考资料

1. 课程资料
2. 本报告的部分文字组织、代码核对与排错分析由 OpenAI Codex 辅助完成。所有实验数据、运行输出和技术描述均由本人检查，最终报告由本人审阅并负责。