

浙江大学

本科实验报告

课程名称:	课程综合实践 I- 深度学习基础——理论与实践
姓 名:	李昊泽
学 院:	计算机科学与技术学院
系:	
专 业:	计算机科学与技术
学 号:	3250102780
指导教师:	王总辉

2026 年 9 月 9 日

浙江大学实验报告

课程名称: 课程综合实践 I- 深度学习基础——理论与实践 实验类型: 综合

实验项目名称: 实验八: Transformer

学生姓名: 李昊泽 专业: 计算机科学与技术 学号: 3250102780

实验地点: 紫金港海洋大楼 11 机房 实验日期: 2026 年 9 月 9 日 指导老师: 王总辉

摘要

本实验包含 Transformer 正弦波预测和 BERT 自然语言处理两部分。

实验原理

一、Transformer 与自注意力

Transformer 不依赖循环结构, 而是通过注意力直接建模序列任意位置之间的关系。给定输入表示 X , 先通过三个线性映射得到查询、键和值:

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

缩放点积注意力为:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

QK^T 衡量不同 token 之间的相关性, 除以 $\sqrt{d_k}$ 可避免维数较大时点积过大, Softmax 则把相关性转换为权重。多头注意力并行计算多组注意力, 使不同子空间可以分别关注局部变化、长距离关系和周期模式:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W_O$$

每个子层外部还包含残差连接和 Layer Normalization; 前馈网络对每个位置的表示作相同的非线性变换。

二、位置编码

注意力本身不包含顺序信息, 因此需要给每个位置加入位置编码。实验采用固定正余弦位置编码:

$$\text{PE}(\text{pos}, 2i) = \sin\left(\frac{\text{pos}}{10000^{2\frac{i}{d}}}\right)$$

$$\text{PE}(\text{pos}, 2i + 1) = \cos\left(\frac{\text{pos}}{10000^{2\frac{i}{d}}}\right)$$

不同频率的正弦、余弦分量使模型能够区分位置，并表达相对距离。正弦波数值先经线性层由 1 维映射到 128 维，再与位置编码相加后送入 Transformer。

三、Encoder-Decoder

Encoder 对已知的 `src` 序列执行自注意力，形成包含整体趋势、周期和相位信息的 memory。Decoder 先对已有的 `tgt` 前缀执行 masked self-attention，再通过 cross-attention 查询 Encoder memory，最后由线性层输出下一时刻的正弦值。

训练时使用真实历史值作为 Decoder 输入，这称为 teacher forcing。为防止模型在预测当前值时看到后面的真实值，需要在 Decoder 中使用上三角因果掩码：

$$M_{i,j} = \begin{cases} 0 & j \leq i \\ -\infty & j > i \end{cases}$$

推理时只给 Decoder 一个起始值，之后把每一步预测追加到输入中：

1 真实 x79 → 预测 x80

[Text](#)

2 预测 x80 → 预测 x81

3 预测 x81 → 预测 x82 → ...

训练使用均方误差：

$$L_{\text{MSE}} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2$$

teacher forcing 每一步都得到真实前值，自回归推理却会反复使用模型自身输出，因此后者更容易累积误差。

四、BERT 与掩码语言模型

BERT 是仅使用 Transformer Encoder 的双向预训练模型。其输入表示由 token embedding、position embedding 和 token-type embedding 相加得到。与自回归 Decoder 只能查看左侧历史不同，BERT 的双向注意力可以同时利用掩码位置两侧的上下文。

掩码语言模型将某个 token 替换为 `[MASK]`。BERT 对该位置输出覆盖整个词表的 logits，再用 `argmax` 取得预测 token：

$$\hat{t} = \operatorname{argmax}_{v \in V} z_v$$

本实验模型词表大小为 28,996，因此长度为 24 的输入对应输出形状 (1, 24, 28996)。

五、抽取式问答

抽取式问答模型不直接生成新句子，而是为输入中的每个 token 分别计算“作为答案起点”和“作为答案终点”的分数。若输出为 s_i 和 e_i ，最简单的解码方式是：

$$i_{\text{start}} = \operatorname{argmax}_i s_i, \quad i_{\text{end}} = \operatorname{argmax}_i e_i$$

随后截取并解码区间 $[i_{\text{start}}, i_{\text{end}}]$ 。实际系统还应约束终点不早于起点，并限制答案最大长度。

实验一：Kaggle Transformer 正弦波预测

一、数据生成

以 0.1 为间隔生成：

$$y_t = \sin(0.1t), \quad t = 0, 1, \dots, 999999$$

二、网络结构

模型由输入映射、位置编码、Transformer 和输出层组成：

模块	尺寸或参数	作用
Encoder 输入映射	Linear(1, 128)	把标量信号映射到高维特征
Decoder 输入映射	Linear(1, 128)	编码已知或已预测的目标前缀
位置编码	max_len=5000	给序列加入时间位置信息
Transformer Encoder	2 层、8 头	提取已知序列的全局依赖
Transformer Decoder	2 层、8 头	结合目标前缀和 Encoder memory
前馈层	128 → 512 → 128	对每个位置作非线性特征变换
输出层	Linear(128, 1)	还原为正弦信号预测值

模型共有 926,849 个可训练参数，Dropout 为 0.1。

三、训练设置与结果

参数	取值	参数	取值
随机种子	42	计算设备	CPU
batch size	512	训练轮数	10
隐藏维度	128	注意力头数	8
Encoder/Decoder 层数	2/2	学习率	10^{-3}
损失函数	MSELoss	优化器	Adam
训练/测试样本数	8000/2000	梯度裁剪阈值	1.0

各轮实际训练 MSE 为：

轮次	训练 MSE	轮次	训练 MSE	轮次	训练 MSE
1	1.545887	2	0.131543	3	0.027146
4	0.013253	5	0.009052	6	0.007009
7	0.005745	8	0.005701	9	0.016929
10	0.015096				





Figure 1: 预测结果

teacher-forcing 预测能够较好贴近真实目标, 而自回归误差约为前者的 20.7 倍。这说明模型具备较好的单步拟合能力, 但连续使用自身预测后误差会传播。

实验二：LMCC BERT 自然语言处理

一、模型加载

```
1 from transformers import AutoTokenizer, AutoModelForMaskedLM
2
3 MODEL_NAME = "google-bert/bert-base-cased"
4 tokenizer = AutoTokenizer.from_pretrained(MODEL_NAME)
5 masked_lm_model = AutoModelForMaskedLM.from_pretrained(MODEL_NAME)
6 masked_lm_model.eval()
```



二、WordPiece 分词

输入文本为：

```
1 I understand equations, both the simple and quadratical.
2 What kind of equations do I understand?
```



编码结果共 24 个 token。关键分词如下：

```
1 [CLS] I understand equations , both the simple and
2 q ##uad ##ratic ##al . [SEP]
3 What kind of equations do I understand ? [SEP]
```



与按空格切分相比，token 数更多，是因为模型加入了 [CLS]、[SEP] 等特殊标记，并把低频词拆成多个 WordPiece 子词。

三、文本分段

第一段正文使用 0，第二段正文使用 1；两个 [SEP] 作为边界。当前实际输出为一个形状为 1x24 的张量：

```
1 tensor([[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
2          1, 1, 1, 1, 1, 1, 1, 1, 1, 1]])
```



四、掩码语言模型

实验把位置 5 的 both 替换为 [MASK]：

```
1 [CLS] I understand equations, [MASK] the simple and
   quadratical.
2 [SEP] What kind of equations do I understand? [SEP]
```



模型利用左右两侧上下文成功恢复了缺失词。




Figure 2: BERT 掩码词预测结果

五、问题回答

目标是把原陈述和问题共同输入 SQuAD 微调后的 BERT，分别获得每个 token 的 `start_logits` 与 `end_logits`，再截取最高分的答案区间。

讨论与改进

一、为什么两种正弦波测试误差差异较大

teacher forcing 使用真实的 x_t 预测 x_{t+1} ，每一步输入都处在训练分布内；自回归推理则使用 $\hat{x}_t$ 预测 $\hat{x}_{t+1}$ 。若第一个预测产生误差 ε_1 ，后续输入分布就开始偏离真实数据，误差会继续影响注意力和解码输出。可尝试降低学习率、保存验证误差最低的模型、向 Decoder 输入加入噪声，或使用 scheduled sampling 缓解训练与推理之间的分布差异。

二、Transformer 与 BERT 的注意力方向

正弦波实验中的 Encoder 可以双向观察整个 `[src]`；Decoder 必须使用 causal mask，只允许观察已生成的目标前缀。BERT 的 masked-LM 则需要结合 `[MASK]` 左右两侧信息，因此采用双向 Encoder 注意力。两者都使用注意力机制，但可见信息范围由任务目标决定。

实验结论

本实验验证了 Transformer 对序列依赖的建模能力。Encoder-Decoder 模型能够从正弦波前缀预测后续信号，但 teacher forcing 与自回归 MSE 的明显差距说明多步生成存在误差累积。BERT 实验展示了 WordPiece、特殊 token、segment ids、双向上下文和 masked-LM 的协同作用，模型成功恢复被遮盖的 `both`。

参考资料

1. 课程资料
2. 本报告的部分文字组织、代码核对与排错分析由 OpenAI Codex 辅助完成。所有实验数据、运行输出和技术描述均由本人检查，最终报告由本人审阅并负责。